

Arbres Lexicogràfics Eficients: Informe

GRAU A – Q1 CURS 2025-2026

Departament de Ciències de la Computació
Universitat Politècnica de Catalunya

LAURA MORENO VALENCIA VICTOR HUERTES MONTES
laura.christel.moreno@estudiant.upc.edu victor.huertes@estudiant.upc.edu

ABRAHAM RUIZ VASQUEZ POL RIVEIRO CLARÀ
abraham.ruiz.vasquez@estudiant.upc.edu pol.riveiro@estudiant.upc.edu

Abstract

Aquest és el resum del vostre treball. Aquí cal escriure una síntesi breu que expliqui de manera clara en què consisteix el projecte, quins són els seus objectius, la metodologia emprada i els principals resultats obtinguts. El document ha de tenir una extensió màxima de 10 pàgines, sense comptar la bibliografia ni els apèndixs (aquests últims són opcionals). Tan important és redactar un bon informe tècnic com elaborar un informe d'autoaprenentatge que reflecteixi el procés seguit, les decisions preses i les dificultats superades. Aquesta plantilla és només una proposta d'organització del document. Podeu adaptar-ne l'estructura segons les necessitats específiques del vostre projecte.

Part I. Informe Tècnic

1 Introducció i Objectius

Un trie és una estructura de dades en forma d'arbre que utilitza l'indexatge de paraules per organitzar informació. Originalment, els tries van ser pensats per recollir una sèrie de strings dintre d'un alfabet fixat, però a la computació moderna són àmpliament utilitzades per eines de predicció i cerca a diversos tipus de dades. L'objectiu d'aquest treball és comprendre el funcionament d'aquestes estructures, implementant diferents optimitzacions de les mateixes i avaluant-les experimentalment.

2 Antecedents

L'estructura de dades trie (també coneguda com a arbre de prefixos) és un arbre ordenat utilitzat per representar una sèrie de paraules (strings) sobre un alfabet finit. Permet que els prefixos comuns facin servir els mateixos nodes,

i emmagatzema només els caràcters que difereixen. Cada node en una trie està associat a un caràcter de l'alfabet, menys el node arrel que és un node buit, i el nombre màxim de fills que pot tenir un determinat node és igual al nombre de caràcters existents en l'alfabet. Pel propòsit d'aquest treball, es farà servir el diccionari ASCII com a referència, de manera que tots els fills quedaran ordenats alfabeticament seguint aquest estandard. El final d'una paraula quedarà representat per un valor associat al node, on s'indicarà l'índex d'aquesta paraula dintre del conjunt del text que es faci servir com a dataset. És important recalcar que, per tal que una paraula aparegui al diccionari constituït per un trie, no cal que sigui un node fulla, ja que es pot fer una indexació de qualsevol node intermig que formi part d'una altra paraula més llarga.




Figure 1: Exemple d'un trie que conté les paraules "at", "ate", "bad", "bed", "beard" i "beat".

Tot i que, en general, les tries són estructures eficients per operacions de cerca de paraules o prefixos, aquesta eficiència normalment significa una penalització en l'ús de memòria. A una implementació bàsica d'un trie, cada node existent tindrà una quantitat de fills igual a la quantitat de caràcters existents en l'alfabet amb el que estem treballant. Això vol dir que en el nostre cas, per exemple, cada node té 128 nodes fills. Notem que a la Figura 1, per simplificació, omitem els fills conformats per nodes buits. Per tant, la complexitat espacial d'un trie d'aquest tipus serà de l'ordre de $O(NM)$, on N representa el nombre de paraules i M la mida màxima d'una paraula.

L'eficiència en termes de memòria ha estat el motor pel desenvolupament de diverses variants de les tries tradicionals. En aquest treball discutirem dues de les principals alternatives: els Ternary Search Trees (TST) i els Radix Trees.

2.1 Ternary Search Trees

Un Ternary Search Tree (o arbre ternari de cerca) és un tipus de trie que busca aprofitar els avantatges espacials dels Binary Search Trees, reduint el número de

fills possibles per un node qualsevol. El seu funcionament és simple: cada node tindrà 3 possibles fills. El fill esquerre (*left child*), el fill dret (*right child*) i el fill central (*middle child*). El valor del fill esquerre haurà de ser un valor menor al del node pare, el del fill dret haurà de ser major, y el fill central serà un punter al valor del següent símbol de la string a qui pertany el node central. Notem que el rendiment d'aquesta estructura depen directament de la profunditat de l'arbre.

3 Disseny i Implementació

En aquest apartat cal descriure amb detall les decisions de disseny i les implementacions realitzades. Cal explicar quines estructures s'han utilitzat, com s'han representat internament i quines operacions s'han implementat (com ara inserció, cerca, autocompletat, etc.), tot destacant com s'ha garantit l'eficiència de cadascuna. També és convenient discutir les possibles alternatives que s'han considerat durant el desenvolupament, així com justificar les opcions escollides. Finalment, s'hauria d'incloure una comparació qualitativa entre les diferents implementacions desenvolupades, tot valorant-ne avantatges, limitacions i aplicabilitat en funció de l'escenari o conjunt de dades.

4 Avaluació Experimental

Aquí cal presentar l'anàlisi empírica del rendiment de les estructures implementades. Es poden descriure els conjunts de dades emprats, les proves realitzades, les mètriques recollides (temps d'execució, memòria, nodes visitats, profunditat mitjana, etc.) i mostrar els resultats obtinguts de manera gràfica o tabulada. Finalment, s'hauria de fer una interpretació crítica dels resultats, contrastant-los amb les expectatives teòriques.

5 Conclusions

En aquesta secció s'han de resumir els principals resultats i aportacions del projecte. Es pot fer una valoració del rendiment assolit, de les dificultats trobades i del coneixement adquirit. També és pertinent incloure possibles extensions, millores o línies futures de treball si el projecte es volgués ampliar. Aquesta secció hauria de tancar el document de forma clara i reflexiva.

Part II. Informe d'Autoaprenentatge

6 Descripció i valoració del procés d'autoaprenentatge

Aquesta part del document complementa l'informe tècnic i reflecteix el vostre procés personal i col·lectiu d'aprenentatge durant el desenvolupament del projecte. L'objectiu és analitzar com heu organitzat el treball, què heu après, quines dificultats heu superat i com heu crescut com a estudiants d'enginyeria.

6.1 Metodologia

Describeix quina ha estat la metodologia emprada per planificar, dividir i executar el projecte. Podeu explicar com heu organitzat el treball en equip (si escau), quines eines heu fet servir per col·laborar o documentar-vos, com heu estructurat el codi i les proves, i com heu abordat l'experimentació. També podeu comentar si heu seguit alguna estratègia iterativa, incremental, àgil o altres enfocaments.

6.2 Valoració del procés d'autoaprenentatge

Reflexioneu sobre els coneixements adquirits, tant teòrics com pràctics. Indiqueu quins aspectes us han resultat més difícils i com els heu resolt, i valoreu fins a quin punt heu assolit els objectius inicials. Podeu mencionar conceptes nous que heu descobert, habilitats tècniques que heu millorat (programació, anàlisi, visualització de dades, etc.) o competències transversals (comunicació, gestió del temps, treball en equip). Si heu canviat d'enfocament durant el projecte, expliqueu el perquè i què heu après en el procés.

Bibliografia

En aquesta part heu d'incloure totes les fonts que heu fet servir pel desenvolupament del projecte, correctament citades i comentades.

Apèndixs (opcionals)

En aquest apartat podeu incloure material addicional que consideri rellevant per complementar el vostre treball, com ara taules, gràfics, fragments de codi, exemples extres, resultats ampliats o documentació tècnica. Tot i que els apèndixs no són obligatoris, poden servir per reforçar o justificar parts de l'informe principal. Tingueu en compte que no seran necessàriament considerats en la correcció si el seu contingut no aporta valor directe a la memòria principal.